



Test de normalité de Shapiro - Wilk

OUSSENI Bicharati ET KOBA Kami

Table des matières

1	Le test de Shapiro-Wilk	3
1.1	Formulation des hypothèses et statistiques d'ordre	3
1.2	Modèle linéaire sous l'hypothèse nulle	4
1.3	Construction des coefficients par moindres carrés généralisés .	4
1.4	Définition de la statistique W	7
2	Propriétés de la statistique W	9
2.1	Propriétés des coefficients a_i	9
2.2	Invariance par translation et changement d'échelle	10
2.3	Encadrement de la statistique W	12
3	Approximation numérique et résultats du test de Shapiro-Wilk	15
3.1	Simulation Monte Carlo sous l'hypothèse nulle	16
3.2	Estimation de la distribution de W	18
3.3	Construction des outils de décision et Génération de la table des quantiles	23
3.4	Puissance du test et comparaison avec la table des quantiles de Shapiro-Wilk	26
3.5	Application sur données réelles — Iris de Fisher	29

Introduction

La normalité des données est une hypothèse fondamentale dans les statistiques, en particulier pour les tests paramétriques et les modèles linéaires, qui reposent sur l'idée que les observations suivent une distribution normale.

Le test de Shapiro-Wilk (1965) est l'un des tests les plus utilisés pour tester cette hypothèse, notamment dans le cas des échantillons de petite taille. Le test repose sur la statistique W , qui compare les données observées avec celles d'une distribution normale théorique. Si les données sont normalement distribuées, les points observés devraient s'aligner sur une droite, et la statistique W devrait être proche de 1.

Ce projet a pour objectif d'expliquer le fonctionnement du test de Shapiro-Wilk, en particulier la statistique W , et de simuler numériquement les quantiles associés. En effet, ces quantiles sont difficiles à obtenir analytiquement, et leur estimation nécessite l'utilisation de méthodes numériques.

Chapitre 1

Le test de Shapiro-Wilk

1.1 Formulation des hypothèses et statistiques d'ordre

Soit $Y_1, \dots, Y_n$ un échantillon de variables aléatoires i.i.d. (indépendantes et identiquement distribuées). On souhaite tester l'hypothèse nulle H_0 :

$$H_0 : Y_1, \dots, Y_n \sim \mathcal{N}(\mu, \sigma^2), \quad \mu \text{ et } \sigma \text{ sont inconnus,}$$

contre l'hypothèse alternative H_1 :

$$H_1 : \text{L'échantillon ne suit pas une loi normale}$$

On ordonne les observations :

$$Y_{(1)} \leq Y_{(2)} \leq \dots \leq Y_{(n)}$$

avec $Y_{(1)} = \min(Y_1, \dots, Y_n)$ et $Y_{(n)} = \max(Y_1, \dots, Y_n)$.

On pose le vecteur **des statistiques d'ordre** :

$$y = \begin{pmatrix} Y_{(1)} \\ Y_{(2)} \\ \vdots \\ Y_{(n)} \end{pmatrix}$$

1.2 Modèle linéaire sous l'hypothèse nulle

Sous l'hypothèse nulle H_0 , on suppose que les Y_i suivent une distribution normale de moyenne μ et de variance σ^2 . Cette hypothèse peut être modélisée à l'aide d'un modèle linéaire, que l'on exprime comme suit :

$$Y(i) = \mu + \sigma m_i + \epsilon_i, \quad i = 1, \dots, n$$

où $m_i = \mathbb{E}(Z(i))$ est l'espérance du i -ème ordre d'un échantillon de $N(0, 1)$. En notation matricielle, en posant :

$$X = \begin{pmatrix} 1 & m_1 \\ 1 & m_2 \\ \vdots & \vdots \\ 1 & m_n \end{pmatrix}, \quad \beta = \begin{pmatrix} \mu \\ \sigma \end{pmatrix}, \quad \epsilon = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}$$

on obtient le modèle linéaire :

$$y = X\beta + \epsilon$$

où X est la matrice de conception, β le vecteur des paramètres, et ϵ le vecteur des erreurs résiduelles.

Ce modèle linéaire permet de relier les statistiques d'ordre aux quantiles théoriques d'une distribution normale. Les erreurs ϵ_i sont supposées être des termes d'erreur indépendants et distribués normalement, de moyenne zéro et de variance σ^2 .

1.3 Construction des coefficients par moindres carrés généralisés

Le test de Shapiro-Wilk repose sur l'idée suivante : si les données proviennent d'une loi normale, alors leurs statistiques d'ordre $Y_{(1)}, \dots, Y_{(n)}$ doivent être liées de façon linéaire aux quantiles théoriques m_i d'une loi normale. On s'attend donc, sous l'hypothèse H_0 , à une relation du type :

$$Y_{(i)} \approx \mu + \sigma m_i.$$

Ainsi, les données ordonnées s'aligneraient sur une droite de pente σ et d'ordonnée à l'origine μ . On cherche donc à estimer ces paramètres.

Modèle et dépendance

On considère le modèle matriciel :

$$y = \mu \mathbf{1} + \sigma m + \epsilon.$$

Comme nous avons ordonné les variables $Y_1, \dots, Y_n$, les statistiques d'ordre $Y_{(i)}$ ne sont pas indépendantes. Leur matrice de covariance est donnée par :

$$V = \text{Cov}(Z_{(i)}, Z_{(j)})_{1 \leq i, j \leq n},$$

qui n'est pas diagonale.

Une estimation par moindres carrés ordinaires n'est donc pas adaptée. On utilise alors les moindres carrés généralisés (MCG), qui prennent en compte cette dépendance.

Fonction à minimiser

On minimise la fonction :

$$L(\mu, \sigma) = (y - \mu \mathbf{1} - \sigma m)^T V^{-1} (y - \mu \mathbf{1} - \sigma m).$$

Après développement, on obtient :

$$L(\mu, \sigma) = y^T V^{-1} y - 2\mu \mathbf{1}^T V^{-1} y - 2\sigma m^T V^{-1} y + \mu^2 \mathbf{1}^T V^{-1} \mathbf{1} + 2\mu \sigma \mathbf{1}^T V^{-1} m + \sigma^2 m^T V^{-1} m.$$

On annule les dérivées :

$$\frac{\partial L}{\partial \mu} = 0, \quad \frac{\partial L}{\partial \sigma} = 0.$$

On obtient alors le système :

$$\begin{cases} -\mathbf{1}^T V^{-1} y + \sigma \mathbf{1}^T V^{-1} m + \mu \mathbf{1}^T V^{-1} \mathbf{1} = 0 \\ -m^T V^{-1} y + \mu \mathbf{1}^T V^{-1} m + \sigma m^T V^{-1} m = 0 \end{cases}$$

Dans le cas d'une loi normale, la symétrie implique :

$$\mathbf{1}^T V^{-1} m = 0.$$

Le système devient :

$$\begin{cases} \mu \mathbf{1}^T V^{-1} \mathbf{1} = \mathbf{1}^T V^{-1} y \\ \sigma m^T V^{-1} m = m^T V^{-1} y \end{cases}$$

On en déduit :

$$\hat{\mu} = \frac{\mathbf{1}^T V^{-1} y}{\mathbf{1}^T V^{-1} \mathbf{1}}, \quad \hat{\sigma} = \frac{m^T V^{-1} y}{m^T V^{-1} m}.$$

Construction des coefficients

On remarque que le numérateur $m^T V^{-1} y$ de l'estimateur de σ dépend directement des données observées, tandis que le dénominateur $m^T V^{-1} m$ ne dépend que de la structure théorique associée à la loi normale.

Ainsi, toute l'information contenue dans les données, du point de vue de l'alignement avec une loi normale, est portée par le terme $m^T V^{-1} y$.

On introduit alors la quantité :

$$b = m^T V^{-1} y,$$

que l'on peut réécrire sous la forme :

$$b = a^T y = \sum_{i=1}^n a_i Y_{(i)} \quad \text{avec} \quad a \propto V^{-1} m.$$

Les coefficients a_i sont déterminés à partir du vecteur des quantiles théoriques m et de la matrice de covariance V , ce qui permet de prendre en compte la dépendance entre les statistiques d'ordre.

Afin de fixer l'échelle de cette combinaison, on normalise le vecteur a et on définit :

$$a = \frac{V^{-1} m}{\|V^{-1} m\|}.$$

Nous savons que sous l'hypothèse de normalité, les statistiques d'ordre vérifient approximativement :

$$Y_{(i)} \approx \mu + \sigma m_i.$$

On en déduit que :

$$a^T y \approx \mu a^T \mathbf{1} + \sigma a^T m.$$

Or, par symétrie, $a^T \mathbf{1} = 0$. Donc :

$$a^T y \approx \sigma a^T m.$$

Ainsi b dépend uniquement de l'écart-type σ et de la structure normale décrite par les quantiles théoriques m .

1.4 Définition de la statistique W

À partir de la section précédente, on a introduit la quantité b qui mesure le degré d'alignement entre les données observées et les quantiles théoriques d'une loi normale.

En effet, les statistiques d'ordre $Y_{(i)}$ et les quantiles théoriques m_i sont tous deux ordonnés. Sous l'hypothèse de normalité, on s'attend à ce que les plus petites observations correspondent aux plus petits quantiles, et les plus grandes aux plus grands quantiles. Autrement dit, les deux suites évoluent de la même façon.

Ainsi, lorsque les données suivent une distribution normale, la valeur de b est élevée.

En revanche, lorsque les données ne sont pas normales, cette correspondance est altérée, notamment en présence d'asymétrie, de valeurs extrêmes ou d'une répartition différente. Dans ce cas, la valeur de b est plus faible.

Comme la quantité b dépend de l'échelle des données (c'est à dire qu'une multiplication des observations par une constante entraîne une variation proportionnelle de sa valeur), on la normalise en la rapportant à la dispersion totale de l'échantillon, afin d'obtenir une statistique indépendante de l'échelle.

Définition :

La statistique de Shapiro-Wilk est alors définie par :

$$W = \frac{\left(\sum_{i=1}^n a_i Y_{(i)}\right)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2} = \frac{b^2}{S^2},$$

où :

$\bar{Y}$ est la moyenne empirique de l'échantillon

$S^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2$ est la variance empirique de l'échantillon.

Chapitre 2

Propriétés de la statistique W

2.1 Propriétés des coefficients a_i

Les coefficients a_i , définis par

$$a = \frac{V^{-1}m}{\|V^{-1}m\|},$$

vérifient les propriétés suivantes :

1. **Normalisation :**

$$\sum_{i=1}^n a_i^2 = 1.$$

Cette propriété résulte de la normalisation du vecteur a

2. **Antisymétrie :** Pour les distributions symétriques,

$$a_i = -a_{n+1-i}, \quad \text{d'où} \quad \sum_{i=1}^n a_i = 0.$$

3. **Optimalité :** La quantité $b = a^T y$ est le meilleur estimateur linéaire sans biais de la pente de la régression des $Y_{(i)}$ sur les quantiles théoriques m_i (à une constante de normalisation près).

En effet, en posant :

$$R^2 = m^T V^{-1} m \quad \text{et} \quad C^2 = m^T V^{-1} V^{-1} m,$$

on a

$$a = \frac{V^{-1}m}{\|V^{-1}m\|} = \frac{V^{-1}m}{C}.$$

Ainsi,

$$b = a^T y = \frac{(V^{-1}m)^T y}{C} = \frac{m^T V^{-1}y}{C}.$$

Or

$$\hat{\sigma} = \frac{m^T V^{-1}y}{m^T V^{-1}m} = \frac{m^T V^{-1}y}{R^2},$$

d'où

$$m^T V^{-1}y = R^2 \hat{\sigma}.$$

Finalement,

$$b = \frac{R^2 \hat{\sigma}}{C}.$$

4. **Approximation robuste :** Pour éviter l'instabilité numérique de V^{-1} pour des tailles d'échantillon élevées (taille supérieure à 50), on utilise l'approximation :

$$a \approx \frac{m}{\|m\|}.$$

Ainsi l'erreur associée est faible (c.f. Shapiro-ApproximateAnalysisVariance-1972).

2.2 Invariance par translation et changement d'échelle

Lemme :

La statistique de Shapiro-Wilk est invariante par transformation affine des données.

Démonstration. Soit un échantillon transformé :

$$Y_i^* = aY_i + b, \quad \text{avec } a > 0.$$

On note W^* la statistique associées aux données transformées.

Invariance par translation

Si l'on ajoute une constante b à toutes les observations, on a :

$$Y_{(i)}^* = Y_{(i)} + b.$$

Alors :

$$b^* = \sum_{i=1}^n a_i Y_{(i)}^* = \sum_{i=1}^n a_i (Y_{(i)} + b) = \sum_{i=1}^n a_i Y_{(i)} + b \sum_{i=1}^n a_i.$$

Or, les coefficients a_i vérifient :

$$\sum_{i=1}^n a_i = 0,$$

donc :

$$b^* = b.$$

De plus, la variance empirique est invariante par translation :

$$S^{*2} = S^2.$$

Ainsi :

$$W^* = W.$$

Invariance par changement d'échelle

Si l'on multiplie les observations par une constante $a > 0$, alors :

$$Y_{(i)}^* = aY_{(i)}.$$

On obtient :

$$b^* = \sum_{i=1}^n a_i Y_{(i)}^* = a \sum_{i=1}^n a_i Y_{(i)} = ab,$$

et :

$$S^{*2} = \sum_{i=1}^n (aY_{(i)} - a\bar{Y})^2 = a^2 S^2.$$

Donc :

$$W^* = \frac{(b^*)^2}{S^{*2}} = \frac{a^2 b^2}{a^2 S^2} = W.$$

Conclusion

La statistique W est donc invariante par translation et changement d'échelle. Elle dépend uniquement de la forme des données, et non de leur position ou de leur unité. □

Corollaire :

La distribution de W sous l'hypothèse de normalité ne dépend que de la taille de l'échantillon n .

2.3 Encadrement de la statistique W

Lemme :

La statistique W vérifie :

$$W \leq 1.$$

Démonstration. Comme W est invariante par translation, on peut supposer sans perte de généralité que $\bar{Y} = 0$. On a alors :

$$W = \frac{\left(\sum_{i=1}^n a_i Y_{(i)}\right)^2}{\sum_{i=1}^n Y_i^2}.$$

D'après l'inégalité de Cauchy-Schwarz :

$$\left(\sum_{i=1}^n a_i Y_{(i)}\right)^2 \leq \left(\sum_{i=1}^n a_i^2\right) \left(\sum_{i=1}^n Y_i^2\right).$$

Or, par normalisation des coefficients, $\sum a_i^2 = 1$. Ainsi :

$$W \leq 1.$$

L'égalité est atteinte si et seulement si $Y_{(i)} = \gamma a_i$ pour un certain $\gamma \in \mathbb{R}$, ce qui correspond à un alignement parfait avec la structure normale. □

Lemme :

La statistique W admet une borne inférieure donnée par :

$$W \geq \frac{na_1^2}{n-1}.$$

Démonstration. Puisque W est invariant par translation et changement d'échelle, on peut supposer sans perte de généralité que :

$$\sum_{i=1}^n Y_i = 0 \quad \text{et} \quad \sum_{i=1}^n a_i Y_{(i)} = 1.$$

Dans ce cas, $W = \frac{1}{\sum Y_i^2}$, de sorte que minimiser W revient à maximiser $\sum Y_i^2$.

Les deux contraintes définissent une région $\mathcal{R}$ convexe, intersection de deux hyperplans. Or $\sum Y_i^2$ est une fonction convexe, donc son maximum sur $\mathcal{R}$ est atteint en un sommet de cette région.

Shapiro & Wilk (1965) montrent que parmi tous les sommets de $\mathcal{R}$, le premier est le point :

$$Y = \left(\frac{n-1}{na_1}, \frac{-1}{na_1}, \dots, \frac{-1}{na_1} \right).$$

On vérifie immédiatement que ce point satisfait les deux contraintes. En ce sommet, on calcule :

$$\sum_{i=1}^n Y_i^2 = \left(\frac{n-1}{na_1} \right)^2 + (n-1) \left(\frac{1}{na_1} \right)^2 = \frac{(n-1)^2 + (n-1)}{n^2 a_1^2} = \frac{n-1}{na_1^2}.$$

Il s'ensuit que $W \geq \frac{1}{\sum Y_i^2} = \frac{na_1^2}{n-1}$. □

Cette borne dépend uniquement de la taille de l'échantillon et des coefficients a_i .

Interprétation

La statistique W est donc comprise entre deux bornes, et en particulier :

$$0 \leq W \leq 1.$$

Elle peut être interprétée comme le rapport entre deux estimations de la variance : le numérateur b^2 , qui capte la part des données conforme à une structure normale, et le dénominateur S^2 , qui correspond à la dispersion totale de l'échantillon.

Elle mesure ainsi le degré d'alignement des données avec les quantiles théoriques d'une loi normale.

Lorsque les données suivent une distribution normale, les statistiques d'ordre sont bien alignées avec les quantiles théoriques, et la valeur de W est proche de 1.

Et lorsque les données sont réparties de manière asymétrique ou qu'elles présentent des valeurs extrêmes, l'alignement est altéré et W diminue.

Chapitre 3

Approximation numérique et résultats du test de Shapiro-Wilk

Dans le cadre du test de Shapiro-Wilk, la décision repose sur la comparaison de la statistique W à sa distribution sous l'hypothèse nulle. Pour déterminer une région critique ou calculer une p-valeur, il est donc nécessaire de connaître la loi de W .

Or, contrairement aux tests classiques, la loi de W est difficile à exploiter, pour deux raisons :

Une densité jointe difficile à exploiter

Comme la statistique W dépend des statistiques d'ordre $Y_{(i)}$, qui sont des variables dépendantes, il est difficile de factoriser leur loi jointe.

Shapiro et Wilk montrent que la distribution de W peut être étudiée à partir d'une densité jointe qui fait intervenir W et une famille de variables angulaires $\theta_1, \dots, \theta_{n-2}$, définie sur une région T :

$$h(W, \theta_1, \dots, \theta_{n-2}) = K W^{-\frac{1}{2}} (1 - W)^{\frac{1}{2}(n-4)} \cos^{n-4}(\theta_2) \cdots \cos(\theta_{n-3}),$$

où K est une constante. Pour obtenir la loi marginale de W , il faudrait intégrer cette densité par rapport aux variables angulaires :

$$f_W(w) = \int_T h(w, \theta_1, \dots, \theta_{n-2}) d\theta_1 \cdots d\theta_{n-2}.$$

Cependant, comme les variables θ_i et la statistique W ne sont pas indépendantes sur la région T , il est difficile de simplifier les calculs pour obtenir

une forme explicite de la loi de W de façon générale, sauf pour deux cas très particuliers (pour $n = 3$ et $n = 4$).

Des moments insuffisants pour les méthodes classiques

Nous ne disposons pas assez d'informations sur les moments de W . En effet, seuls certains moments, comme ceux d'ordre $\frac{1}{2}$ et 1, ont pu être déterminés. Par conséquent, les méthodes d'approximation classiques, comme le développement de Cornish-Fisher, ne peuvent pas être utilisées.

Nous allons donc utiliser des méthodes numériques pour approximer W et prendre une décision.

3.1 Simulation Monte Carlo sous l'hypothèse nulle

Afin d'approximer la distribution de la statistique W , nous avons réalisé une simulation de Monte Carlo sous l'hypothèse de normalité à l'aide du langage Python.

Implémentation de la simulation

Dans un premier temps, pour chaque taille d'échantillon n , nous avons généré un grand nombre N_{sim} d'échantillons indépendants suivant une loi normale centrée réduite :

$$Z^{(k)} = (Z_1^{(k)}, \dots, Z_n^{(k)}) \sim \mathcal{N}(0, 1), \quad k = 1, \dots, N_{\text{sim}}.$$

Chaque échantillon est ensuite trié afin d'obtenir les statistiques d'ordre :

$$Z_{(1)}^{(k)} \leq \dots \leq Z_{(n)}^{(k)}.$$

À partir de ces simulations, nous avons estimé empiriquement le vecteur des espérances des statistiques d'ordre :

$$\hat{m}_i = \frac{1}{N_{\text{sim}}} \sum_{k=1}^{N_{\text{sim}}} Z_{(i)}^{(k)},$$

ainsi que la matrice de covariance associée.

Les coefficients a sont ensuite approchés à l'aide de la formule robuste :

$$a \approx \frac{\hat{m}}{\|\hat{m}\|},$$

ce qui permet d'éviter l'inversion de la matrice de covariance, souvent instable lorsque la taille n devient grande.

Une fois les coefficients a fixés, la statistique W est calculée pour chaque échantillon simulé :


$$W^{(k)} = \frac{(a^T Z^{(k)})^2}{\sum_{i=1}^n \left(Z_i^{(k)} - \bar{Z}^{(k)} \right)^2}.$$

Cette procédure est répétée pour un grand nombre de simulations (jusqu'à $N_{\text{sim}} = 10^6$ dans notre cas), ce qui permet d'obtenir une approximation numérique de la distribution de W pour chaque taille d'échantillon n .

Temps de calcul et sauvegarde des données

La simulation Monte Carlo utilisée pour approximer la distribution de W est coûteuse en temps de calcul, en particulier en raison du grand nombre de simulations effectuées pour chaque taille d'échantillon.

Dans notre implémentation, le temps total d'exécution pour les tailles $n = 3$ à $n = 100$ a nécessité environ 56 minutes.



```
print("Temps d'exécution : {:.2f} minutes".format(duree_minutes))
```

... Temps d'exécution : 56.42 minutes

FIGURE 3.1 – Temps d'exécution de la simulation

Les coefficients a ainsi que les valeurs simulées de W sont ensuite sauvegardés dans des fichiers, afin d'être réutilisés pour l'estimation des quantiles critiques et des p-valeurs.

Afin d'éviter de répéter ces calculs coûteux, nous avons sauvegardé les coefficients a pour chaque taille n ainsi que les valeurs simulées de W .

Ce qui nous permet de réutiliser directement les résultats pour l'estimation des quantiles et des p-valeurs, sans relancer les simulations tout en réduisant le temps des calculs.

3.2 Estimation de la distribution de W

Fonction de répartition empirique

Afin d'estimer la fonction de répartition :

$$F(w) = \mathbb{P}(W \leq w).$$

On a utilisé les simulations pour construire une approximation empirique :

$$\hat{F}_N(w) = \frac{1}{N} \sum_{k=1}^N \mathbf{1}_{\{W^{(k)} \leq w\}},$$

qui correspond à la proportion de valeurs simulées inférieures ou égales à w . Pour construire cette fonction, nous avons d'abord trié les valeurs W par ordre croissant, afin d'obtenir une fonction croissante.

À chaque valeur $W_{(k)}$, nous associons la proportion $\frac{k}{N}$.

D'après la loi des grands nombres, on a alors :

$$\hat{F}_N(w) \xrightarrow[N \rightarrow \infty]{} \mathbb{E}[\mathbf{1}_{\{W \leq w\}}] = \mathbb{P}(W \leq w).$$

Ainsi, lorsque le nombre de simulations N est suffisamment grand, la fréquence empirique $\hat{F}_N(w)$ converge vers la probabilité théorique $F(w)$.

Estimation de la densité (KDE)

Pour mieux visualiser la répartition des valeurs simulées, nous avons aussi estimé la densité de probabilité de la statistique W grâce à la méthode des noyaux (Kernel Density Estimation, KDE), qui consiste à lisser les données pour obtenir une courbe continue à partir des observations simulées. Plus précisément, la densité est estimée par :

$$\hat{f}_N(x) = \frac{1}{Nh} \sum_{k=1}^N K\left(\frac{x - W^{(k)}}{h}\right),$$

où K est une fonction gaussienne et h est un paramètre de lissage.

L'idée est la suivante : à chaque valeur simulée, on associe une petite courbe en forme de cloche centrée sur cette valeur, puis on additionne toutes ces courbes pour obtenir une estimation lisse de la densité.

Le paramètre h , appelé *bandwidth*, contrôle le niveau de lissage :

- si h est trop petit, la courbe est irrégulière et bruitée,
- si h est trop grand, la courbe est trop lissée et perd des détails.

Distribution de W pour différentes tailles d'échantillon

Nous présentons ci-dessous les résultats obtenus pour plusieurs tailles d'échantillon ($n = 5, 10, 20, 30$), à travers la fonction de répartition empirique et la densité estimée de la statistique W .




FIGURE 3.2 – Distribution de W sous H_0 pour différentes tailles d'échantillon

Observations : Plus la taille de l'échantillon augmente, plus $W_{\min}$ est faible : elle vaut environ 0,5126 pour $n = 5$ et 0,1560 pour $n = 30$.

Lorsque la taille de l'échantillon est petite, les valeurs de W sont plus dispersées et la fonction de répartition augmente progressivement.

À l'inverse, lorsque n augmente, les valeurs de W se concentrent davantage vers 1, et la courbe devient plus raide (Les valeurs montent rapidement vers 1).

Conclusion : La distribution de W se concentre progressivement vers 1 lorsque la taille de l'échantillon augmente. Cela signifie que la statistique devient plus stable et moins variable.

En pratique, cette évolution rend le test de Shapiro-Wilk plus sensible aux écarts à la normalité pour des tailles d'échantillon plus élevées.

Densité de W pour différentes lois

Pour explorer le comportement de la statistique W , comparons sa densité sous plusieurs lois de probabilité, telles que la loi normale, la loi de Laplace, la loi exponentielle, la loi uniforme et la loi χ^2 .




FIGURE 3.3 – Densité de la statistique W pour différentes lois de probabilité.

Observations :

- **loi normale** : la densité de W est concentrée entre 0.95 et 1, avec des valeurs de W proches de 1.
- **Loi exponentielle** et **loi χ^2** (3 degrés de liberté) : La densité est plus décalée vers la gauche, indiquant une forte asymétrie. Le test est particulièrement puissant pour détecter ces écarts à la normalité.
- En revanche, pour des lois moins asymétriques comme la **loi uniforme** et la **loi de Laplace**, le test peut être **moins efficace**. La loi de Laplace, bien qu'elle présente une forme de **cloche** similaire à la loi normale, elle a des **queues plus épaisses**. Quant à la loi uniforme, elle a une **distribution constante** sur un intervalle donné, ce qui la rend très différente de la normale

On observe sur le graphique que les densités de la loi uniforme et de la loi

de Laplace se chevauchent beaucoup avec celle de la loi normale. Pour une taille d'échantillon $n = 20$, le test a encore des difficultés à distinguer ces lois de la loi normale.

Conclusion : Ces résultats montrent que le test de Shapiro-Wilk est très efficace pour détecter les asymétries, mais il est moins sensible aux différences de "forme" (aplatissement ou épaisseur des queues) sur de petits échantillons.

Convergence de W lorsque n augmente

Analysons maintenant le comportement de la statistique W pour les différentes lois en fonction de la tailles de l'échantillon :




FIGURE 3.4 – Convergence de la statistique W lorsque n augmente pour différentes lois.

Observations :

- **Loi normale :** Plus la taille de l'échantillon n augmente, plus W se rapproche de 1. Cela confirme que, pour de grands échantillons, la statistique W converge vers la normale, comme prévu par l'hypothèse nulle H_0 .

- **Loi de Laplace et loi uniforme** : Les valeurs de W restent relativement élevées, bien que plus basses que pour la loi normale. Ces deux lois présentent un comportement similaire à celui de la loi normale, mais leur convergence vers 1 est plus lente.
- **Loi du χ^2 (3 ddl) et loi exponentielle** : Les valeurs de W sont plus faibles, avec une tendance plus marquée à s'éloigner de 1. En particulier, pour la loi exponentielle, W diminue progressivement lorsque n augmente et finit par se stabiliser à une certaine valeur.

Conclusion : L'efficacité du test croît avec la taille de l'échantillon, particulièrement pour les lois éloignées de la normale.

Comportement de W : Croisement entre les lois et les seuils

Examinons le croisement entre les lois et les seuils de rejet pour la statistique W en fonction de la taille de l'échantillon.




FIGURE 3.5 – Comportement de la statistique W : Croisement entre les lois et les seuils.

Observations :

- **Loi exponentielle :** La valeur moyenne de W reste inférieure à 0,85, ce qui la place sous tous les seuils de rejet même pour de petits échantillons (n faible). Le test est donc immédiatement efficace pour détecter l'asymétrie.
- **Loi de Laplace et loi uniforme :** Pour des tailles d'échantillon $n < 30$, les valeurs moyennes de W se situent au-dessus du seuil de rejet. Le test échoue donc souvent à rejeter la normalité pour ces lois avec un risque de 5%.
- **Échantillons de grande taille ($n > 50$) :** Les courbes de W pour les différentes lois se trouvent dans la zone de rejet rose. Plus n augmente, plus le test devient sensible et rejette facilement l'hypothèse nulle, même pour la loi uniforme.

Conclusion : Le test de Shapiro-Wilk se distingue par sa puissance pour tester la normalité. Il est capable de détecter rapidement les lois asymétriques, même pour des échantillons de petite taille. Cependant, pour rejeter des lois symétriques non normales de manière fiable, une taille d'échantillon plus grande ($n > 50$) est indispensable.

3.3 Construction des outils de décision et Génération de la table des quantiles

La région critique

Comme nous l'avons vu plus haut, lorsque les données s'écartent de la normale, la valeur de la statistique W diminue. Par conséquent, la région critique R_α est unilatérale à gauche. Elle est définie par l'ensemble des valeurs inférieures au quantile d'ordre α :

$$R_\alpha = \{w \mid w < W_\alpha(n)\}$$

où $W_\alpha(n)$ est le seuil critique (ou quantile d'ordre α) pour un échantillon de taille n .

Approximation de la p-valeur

On définit la p-valeur comme suit :

$$\text{P-value} = \mathbb{P}(W \leq w_{\text{obs}} \mid H_0)$$

Elle correspond à la proportion de valeurs simulées de W qui sont inférieures ou égales à W_{obs} .

Numériquement, pour N simulations, la p-valeur est estimée par :

$$\hat{p} = \frac{1}{N} \sum_{k=1}^N \mathbf{1}_{\{W^{(k)} \leq W_{\text{obs}}\}}$$

La règle de décision

On calcule la valeur de W_{obs} à partir des données :

- **Si** $W_{\text{obs}} < W_{\alpha}(n)$ ou si $\hat{p} < \alpha$: On rejette H_0 . On conclut que l'échantillon ne suit pas une loi normale avec un risque d'erreur α .
- **Si** $W_{\text{obs}} \geq W_{\alpha}(n)$ ou si $\hat{p} \geq \alpha$: On conserve H_0 . On ne peut pas rejeter l'hypothèse de normalité. On n'a pas de preuve suffisante pour dire que ce n'est pas normal.

La table des quantiles

À partir des valeurs simulées de la statistique W , nous avons calculé les quantiles pour différents niveaux de risque $\alpha \in \{0.01, 0.02, 0.05, 0.10, 0.50, 0.90, 0.95, 0.99\}$ et pour chaque taille d'échantillon n .

Pour un niveau de risque α , le quantile $W_{\alpha}(n)$ est défini par :

$$\mathbb{P}(W \leq W_{\alpha}(n) \mid H_0) = \alpha$$

Ce qui signifie que $W_{\alpha}(n)$ est la valeur de la statistique W en dessous de laquelle se trouve une proportion α des valeurs simulées sous l'hypothèse nulle H_0 .

Voici la table des quantiles obtenus pour les tailles d'échantillon clés $n \in \{3, 4, 5, 6, 7, 8, 9, 10, 12, 15, 20, 25, 30, 35, 40, 45, 50, 60, 70, 80, 90, 100\}$ et les niveaux de risque définis :

n	0.01	0.02	0.05	0.10	0.50	0.90	0.95	0.99
3	0.7544	0.7589	0.7722	0.7939	0.9328	0.997	0.9993	1.0017
4	0.6793	0.7049	0.7523	0.7994	0.9181	0.9834	0.9917	0.9984
5	0.6721	0.7121	0.7689	0.8118	0.9195	0.9765	0.988	1.0084
6	0.7009	0.7376	0.7886	0.8288	0.9253	0.9728	0.9809	0.9915
7	0.72	0.7558	0.8046	0.8417	0.9295	0.9721	0.9796	0.9893
8	0.7385	0.7728	0.8187	0.8532	0.9338	0.9725	0.9792	0.9884
9	0.7563	0.7883	0.8314	0.8633	0.9377	0.9731	0.9793	0.9878
10	0.7716	0.8017	0.8421	0.873	0.9412	0.9744	0.9797	0.989
12	0.7958	0.8239	0.8597	0.8866	0.9471	0.9757	0.9807	0.9877
15	0.8255	0.8495	0.8802	0.903	0.9541	0.9782	0.9824	0.9883
20	0.8648	0.8778	0.9012	0.9198	0.9621	0.9814	0.9848	0.9902
25	0.8815	0.8978	0.9186	0.9337	0.9677	0.9838	0.9866	0.9906
30	0.8958	0.912	0.9309	0.9435	0.9717	0.9853	0.9877	0.9913
35	0.9101	0.9222	0.9377	0.949	0.9747	0.987	0.9891	0.9922
40	0.9191	0.9303	0.9441	0.9543	0.9771	0.9881	0.99	0.9928
45	0.9274	0.9369	0.9494	0.9585	0.9792	0.9891	0.9908	0.9933
50	0.9334	0.9424	0.9537	0.962	0.9808	0.9898	0.9915	0.9938
60	0.9433	0.9508	0.9604	0.9674	0.9833	0.9911	0.9925	0.9945
70	0.9505	0.957	0.9653	0.9714	0.9853	0.9921	0.9933	0.9951
80	0.956	0.9618	0.9691	0.9744	0.9868	0.9929	0.9939	0.9955
90	0.9605	0.9656	0.9722	0.9769	0.988	0.9935	0.9945	0.9959
100	0.964	0.9687	0.9746	0.9789	0.989	0.994	0.9949	0.9962

TABLE 3.1 – Table des quantiles critiques pour différentes tailles d'échantillon (tailles clés) et niveaux de significativité.

Table des quantiles pour toutes les tailles

La table complète des quantiles pour toutes les tailles d'échantillon n de 3 à 100 est disponible en ligne. Vous pouvez consulter cette table en cliquant sur le lien suivant :

Table Quantiles Shapiro annexe.csv

3.4 Puissance du test et comparaison avec la table des quantiles de Shapiro-Wilk

Étude de la puissance du test

La **puissance** du test mesure sa capacité à rejeter H_0 lorsque les données ne proviennent pas d'une loi normale.

Pour l'estimer, nous avons simulé $N_{\text{sim}} = 5000$ échantillons de taille n provenant des lois classiques vues plus haut, et nous avons calculé la proportion de fois où le test rejette H_0 avec un niveau de risque $\alpha = 5\%$.




FIGURE 3.6 – Puissance du test de Shapiro-Wilk face à différentes lois non normales.

Observations :

- **Loi exponentielle** : Comme nous nous attendions, la puissance est très élevée dès les petits échantillons.
- **Loi de Laplace** : La puissance augmente progressivement n lorsque n augmente.

- **Loi uniforme** : La puissance reste relativement faible pour les petits échantillons et commence à augmenter progressivement pour n supérieur à 30.

Analyse approfondie de la loi uniforme :

Comme la loi uniforme est la plus difficile à détecter, nous avons calculé le taux d'erreur de type II, c'est-à-dire la proportion de fois où le test ne rejette pas H_0 alors que les données ne sont pas normales :

$$\text{Erreur de type II} = 1 - \text{Puissance}.$$




FIGURE 3.7 – Taux d'erreur de type II pour la loi uniforme.

Observation : Pour n inférieur à 30, le taux d'erreur est supérieur à 80%, et il diminue à mesure que la taille de l'échantillon augmente. Cependant, ce taux reste encore élevé même pour $n = 50$. À partir de $n = 90$, le taux d'erreur passe enfin sous le seuil des 5%, ce qui indique que le test devient vraiment fiable pour des échantillons plus grands.

Comparaison avec les tables de Shapiro-Wilk

Pour vérifier que notre implémentation est correcte, nous avons comparé les quantiles obtenus par notre simulation avec les valeurs de référence de la Table 6 de Shapiro & Wilk (1965).

Pour chaque taille n et chaque niveau α , on calcule l'erreur absolue :

$$\text{Erreur} = |\hat{q}_\alpha^{\text{simulé}} - q_\alpha^{\text{SW 1965}}|.$$




FIGURE 3.8 – Comparaison des quantiles simulés avec ceux de Shapiro & Wilk (1965) pour $\alpha = 1\%$ et $\alpha = 5\%$.

Observations :

- Les deux courbes se superposent très bien pour toutes les tailles n , ce qui confirme que notre simulation est correcte.
- L'erreur absolue moyenne est de 0,004, ce qui est très faible.
- L'erreur maximale de 0,026 s'observe pour les petits échantillons et pour les quantiles extrêmes (par exemple $\alpha = 1\%$), car les événements rares sont plus difficiles à estimer par simulation.
- Les petites différences observées proviennent du fait que Shapiro et Wilk ont appliqué un lissage à leurs résultats à l'aide des courbes S_B de Johnson, alors que nos valeurs proviennent directement des simulations Monte Carlo.

Conclusion : Les résultats obtenus montrent que nos simulations reproduisent correctement la distribution théorique de la statistique W . Avec $N_{\text{sim}} = 10^6$, les quantiles simulés sont donc suffisamment précis pour une application pratique du test.

3.5 Application sur données réelles — Iris de Fisher

Pour illustrer l'utilisation concrète du test, nous l'appliquons à un jeu de données réel : les mesures de longueur des sépales de l'espèce *Iris setosa* issues du célèbre jeu de données de Fisher (1936), composé de 50 observations.




FIGURE 3.9 – Histogramme et Q-Q plot des longueurs de sépales — *Iris setosa*.

Observations : L’histogramme des données montre une forme en cloche, avec une concentration marquée autour de la moyenne. Sur le diagramme Q-Q, les points s’alignent bien sur la droite théorique, mais on observe quelques déviations aux extrémités.

En effectuant le test sur nos données, on obtient les résultats suivants :

$$W_{\text{obs}} = 0,9788, \quad \hat{p} = 0,423.$$

Comme la p-valeur est largement supérieure à $\alpha = 5\%$, on conserve donc H_0 . Les longueurs de sépales de l’espèce *Iris setosa* sont compatibles avec une distribution normale.

Conclusion

Comment savoir si des données suivent une loi normale ? C'est précisément ce que Shapiro & Wilk ont tenté de résoudre en 1965. La statistique W mesure l'alignement des valeurs ordonnées avec les quantiles théoriques d'une normale : plus elle est proche de 1, plus les données sont normales. Avec $N_{\text{sim}} = 10^6$ simulations, nous avons retrouvé leur table de quantiles avec une erreur moyenne de 0,004. Le test est très puissant face aux lois asymétriques, mais nécessite $n \geq 90$ pour être fiable face à la loi uniforme. Ce projet nous a permis de comprendre, reconstruire et vérifier ce test et pas seulement l'utiliser.